

陕西科技大学

毕 业 设 计



题目： 基于视觉模型的医学图像异常检测系统的
设计与实现

学 生： 魏雨蒙

学 号： 202107020623

学 院： 电子信息与人工智能学院

专 业： 网络工程

指导教师： 丁磊

2025 年 6 月

基于视觉模型的医学图像异常检测系统的设计与实现

摘要

医学图像在临床诊断中扮演着至关重要的角色，其分析与解读高度依赖于专业的医学知识和丰富的实践经验。传统医学图像异常检测方法主要依赖手工设计特征，这种方法存在计算复杂度高、泛化能力不足等显著局限性。随着计算机视觉和深度学习技术的迅猛发展，基于深度学习和视觉-语言模型的医学图像异常检测逐渐成为研究热点。本研究基于 CLIP 模型实现了一种改进的医学图像异常检测算法，提高了检测的准确性、客观性和效率，并设计开发了一个异常检测系统。

首先，本文将 CLIP 模型应用到医学图像异常检测中。CLIP 模型作为一种创新的视觉-语言模型，通过对比学习将图像和文本嵌入到统一的语义空间中，实现了跨模态的理解与生成。该模型由图像编码器和文本编码器两个核心部分构成。图像编码器基于 Vision Transformer 或深度卷积神经网络，能够将图像数据转化为高维特征表示；而文本编码器则基于 Transformer 架构，用于处理自然语言文本并生成文本特征嵌入。通过联合训练，CLIP 模型使图像和文本特征在嵌入空间中实现语义对齐。采用对比损失函数，通过缩小正样本对的距离并扩大负样本对的距离，模型能够学习到图像和文本之间的语义关联。

其次，本文对 CLIP 模型进行了改进，提升了医学图像异常检测的性能。通过在 CLIP 的视觉编码器中引入多级残差适配器，显著增强了模型对医学图像特征的提取能力。这些适配器能够逐步优化视觉特征，使模型能够更有效地捕捉医学图像中的异常信息。此外，为了使视觉特征能够更好地与文本特征对齐，本文对视觉-文本特征对齐过程进行了优化。在训练阶段，通过最小化多层级像素级视觉-文本特征对齐损失函数来优化模型参数。损失函数由 Dice 损失、焦点损失和二元交叉熵损失组成，这种多损失函数的组合能够确保模型在不同语义层级上学习视觉模式与文本描述的关联，从而增强模型对未见医学成像模态及解剖区域的泛化能力。

最后，本文基于上述方法开发了一种功能完备的医学图像异常检测系统。该系统能够实现用户管理、图像检测、结果展示与评估等多项功能。系统功能设计涵盖了用户管理、图像检测、结果展示与评估等功能模块，测试结果表明该系统具有良好的稳定性和准确性。

关键词：医学图像异常检测，CLIP 模型，多层级语义映射，可学习文本提示，Web 应用系统

Design and Implementation of a Medical Image Anomaly Detection System Based on Visual Models

ABSTRACT

Medical images play a crucial role in clinical diagnosis, with their analysis and interpretation highly dependent on specialized medical knowledge and extensive practical experience. Traditional medical image anomaly detection methods primarily rely on manually designed features, which have significant limitations such as high computational complexity and poor generalization ability. With the rapid development of computer vision and deep learning technologies, medical image anomaly detection based on deep learning and visual - language models has gradually become a research hotspot. This study implements an improved medical image anomaly detection algorithm based on the CLIP model, enhancing the accuracy, objectivity, and efficiency of detection, and designs and develops an anomaly detection system.

Firstly, this paper applies the CLIP model to medical image anomaly detection. As an innovative visual - linguistic model, CLIP employs contrastive learning to embed images and text into a unified semantic space, enabling cross - modal understanding and generation. The model consists of two core components: an image encoder and a text encoder. The image encoder, based on Vision Transformers or deep convolutional neural networks, is capable of transforming image data into high - dimensional feature representations. The text encoder, based on a Transformer architecture, processes natural language text to generate text feature embeddings. Through joint training, the CLIP model achieves semantic alignment of image and text features in the embedding space. By utilizing a contrastive loss function that reduces the distance between positive sample pairs and increases the distance between negative sample pairs, the model is able to learn the semantic relationships between images and text.

Secondly, this paper improves the CLIP model to enhance the performance of medical image anomaly detection. By introducing multi - level residual adapters into the visual encoder of CLIP, the model's ability to extract features from medical images is significantly strengthened. These adapters gradually refine visual features, enabling the model to more effectively capture abnormal information within medical images. In addition, to better align visual features with text features, this paper optimizes the visual - text feature alignment process. During the training phase, the model parameters are optimized by minimizing a multi - level pixel - level visual - text feature alignment loss function. This loss function is composed of Dice loss, focal loss, and binary cross - entropy loss. The combination of these

multiple loss functions ensures that the model learns the correlation between visual patterns and text descriptions across different semantic levels. As a result, the model's generalization capability to unseen medical imaging modalities and anatomical regions is enhanced.

Finally, based on the above - mentioned methods, this paper develops a fully - functional medical image anomaly detection system. The system is capable of performing various functions, including user management, image detection, result display, and evaluation. The system's functional design encompasses modules for user management, image detection, result display, and evaluation. Testing results indicate that the system possesses good stability and accuracy.

Key words: medical image anomaly detection, CLIP model, hierarchical semantic mapping, learnable text prompts, web application development

目 录


摘 要	I
ABSTRACT	II
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 基于传统图像处理的医学图像异常检测方法	2
1.2.2 基于深度学习的医学图像异常检测方法	3
1.2.3 基于多模态视觉-语言模型的医学图像异常检测方法	4
1.3 论文的主要内容与结构安排	5
1.3.1 本文的核心贡献与技术方案概览	5
1.3.2 论文的组织架构与章节内容提要	5
2 相关理论基础	7
2.1 视觉—语言模型总述	7
2.1.1 CLIP 模型的架构	7
2.1.2 视觉编码器: Vision Transformer 网络模型	8
2.1.3 文本编码器与可学习文本提示	9
2.2 适配器	10
2.2.1 分割适配器	11
2.2.2 分类适配器	11
2.3 多级特征处理技术总述	12
2.3.1 特征对齐	13
2.3.2 对比学习	13
2.4 实验指标与数据集	13
2.4.1 评价指标	14
2.4.2 多模态数据集	15
2.4.3 相似度计算	16
3 基于改进 CLIP 的跨模态特征适配与识别	18
3.1 总体框架	18
3.1.1 CLIP 优化策略	19
3.1.2 医学图像特征的多层级语义映射	20
3.1.3 跨模态特征融合方法	20
3.1.4 基于 ATPrompt 的可学习文本提示	21

3.2 实验验证	23
3.2.1 实验配置	23
3.2.2 性能指标	23
3.2.3 实验结果	24
3.2.4 结果分析	24
4 医学图像异常检测系统设计与实现	25
4.1 系统功能设计	25
4.2 系统实现与测试	25
4.2.1 用户管理模块	25
4.2.2 检测模块	26
4.2.3 结果展示模块	26
4.2.4 评估模块	27
4.3 系统测试	28
4.3.1 测试目标	28
4.3.2 测试方法	28
4.3.3 测试用例	28
4.3.4 测试结论	29
5 总结与展望	30
5.1 本文工作总结	30
5.2 未来研究方向	30
致 谢	31
参 考 文 献	32

1 绪论

1.1 研究背景与意义

随着医疗技术的不断进步，医学图像在临床诊断中的作用日益凸显。医学图像，如X光、CT、MRI等，为医生提供了丰富的视觉信息，帮助他们更准确地诊断疾病、监测病情进展以及制定治疗方案。然而，医学图像的分析 and 解读需要专业的医学知识和丰富的经验，这对医生的工作效率、专业性和准确性提出了巨大挑战。医学图像异常检测是指通过分析医学图像来识别其中的异常区域或特征，从而辅助医生进行疾病诊断和治疗决策的过程，如图1所示，这一过程通常涉及对X光、CT、MRI等医学图像的处理和分析，以区分正常组织与异常病变，例如肿瘤、炎症或骨折等。随着医疗数据量的不断增加，如何快速、准确地从海量医学图像中识别出异常区域，在医疗数据量日益膨胀的背景下，从海量医学图像中高效、准确地检测出异常区域，已然成为医学图像分析领域备受关注的研究焦点。



1-1 异常检测可视化示意图

近年来，计算机视觉与深度学习技术的飞速进步，为医学图像异常检测领域带来了全新的应对策略，随着计算机视觉的发展，为图像的快速检测提供可能。依托新技术的产生，基于视觉模型的医学图像异常检测系统设计与开发成为一个热门任务，该系统能够显著提高诊断效率，通过自动识别和标记图像中的异常区域，减少医生在图像分析上花费的时间，从而提高整体的诊断速度。同时，该系统通过学习大量的标注数据，自动筛选出高风险的图像，能够捕捉到一些肉眼难以察觉的细微异常，从而提高诊断的准确性，帮助医生更早地发现疾病，优先处理可能存在问题的病例，提高治疗效果。例如，基于卷积神经网络（CNN）的深度学习模型系统已经在医学图像分类和分割任务中取得了显著的成果，展示了其在异常检测中的潜力^[1]。

基于视觉-语言模型（VLM）的医学图像异常检测系统与传统的基于卷积神经网络（CNN）的深度学习模型系统相比，具有显著的优势。传统的 CNN 模型主要依赖于图像数据本身，通过学习图像的特征来进行异常检测，而 VLM 则结合了图像和文本信息，能够更全面地理解和分析医学图像中的异常模式。这种多模态的方法不仅能够提高异常检测的准确性，还能够通过文本信息提供更丰富的解释和背景知识，帮助医生更好地理解检测结果。此外，VLM 在处理数据稀缺的情况时表现出色，能够有效利用未标注数据进行预训练，减少对标注数据的依赖，从而在实际应用中更具灵活性和适应性。




图 1-2 基于视觉语言模型的医学图像异常检测过程

1.2 国内外研究现状

1.2.1 基于传统图像处理的医学图像异常检测方法

在医学图像异常检测的早期探索中，研究者们主要依赖于传统图像处理技术。这些技术通过手工设计的特征来识别图像中的异常模式，为后续的智能检测方法奠定了基础。例如，Ojala 等人^[4]提出了一种基于 Kullback-Leibler 散度的分类方法，在医学图像异常检测中，KL 散度通过比较样本特征分布与已知的正常或异常分布之间的差异来判断样本的类别。通过从医学图像中提取特征，然后建立正常和异常分布的概率模型。对于新的图像样本，计算其特征分布与正常和异常分布之间的 KL 散度，选择 KL 散度较小的分布作为样本的类别。这种方法基于概率分布的比较，具有坚实的统计基础，能够直观地理解样本与已知分布之间的差异，但在面对复杂的医学图像时，其计算复杂度较高且非对称性可能导致解释上的困难。纹理分析是另一类重要的传统图像处理技术。Haralick 等人提出的灰度共生矩阵（GLCM）方法^[2]，通过计算图像像素的灰度值之间的空间关系，提取图像的纹理特征。这一方法在分析组织结构的均匀性和粗糙度方面表现出色。此外，Laws 纹理能量测量方法通过设计一组方向滤波器，能够有效地捕捉图像中的方向性和周期性纹理特征。这些方法在特定场景下取得了成功，但其性能高度依赖于图像的质量和手工特征的设计，缺乏对复杂医学图像的自适应能力。

近年来, 研究者们开始探索将多种传统图像处理技术相结合, 以提高异常检测的性能。例如, Mangattu 等人结合阈值分割和纹理分析的方法, 先通过阈值分割确定感兴趣的区域, 再利用纹理分析进行细致的特征提取和分类^[3]。这种方法在处理多模态医学图像时表现出色, 能够有效减少误报和漏报。然而, 传统方法在处理大规模、多样化的医学图像数据时, 仍然面临计算复杂度高和泛化能力不足的问题。这些局限性促使研究者们转向深度学习技术, 以期在医学图像异常检测领域取得更大的突破。

1.2.2 基于深度学习的医学图像异常检测方法

在深度学习技术的强劲推动下, 医学图像异常检测领域开启了新的篇章。深度学习方法凭借其自动提取图像特征的能力, 克服了传统方法的局限性。卷积神经网络及其变体被广泛应用于医学图像异常检测, 能够自动提取图像的高级特征并进行分类或分割。Cai 等人^[1]提出了一种基于生成对抗网络的异常检测方法, 通过生成对抗网络来学习正常图像的分布, 从而检测出异常样本。这种方法在处理复杂医学图像时表现出色, 能够有效捕捉图像中的细微异常特征。为了进一步提高检测性能, 研究者们提出了多种改进的深度学习架构。例如, Ronneberger 等人提出的 U-Net 网络^[5], 通过编码器-解码器结构和跳跃连接, 能够有效地保留图像的细节信息, 适用于医学图像的分割任务。此外, Huang 等人提出的 DenseNet^[6]通过密集连接的块结构, 增强了特征的传播和复用, 提高了模型的表达能力。这些改进的网络架构在医学图像检测中取得了显著的成果, 尤其是在处理高分辨率图像时, 能够保持较高的检测精度。




图 1-3 GNN 和 CNN 的详细视图^[15]

除了网络架构的改进, 研究者们还探索了不同的训练策略和损失函数。例如, Goodfellow 等人提出的对抗性训练方法^[7], 通过引入生成器和判别器的对抗过程, 能够

使模型学习到更鲁棒的特征表示。此外，Lin 等人提出的 Focal Loss^[8]解决了类别不平衡问题，使得模型在处理罕见异常时能够取得更好的性能。这些方法不仅提高了检测的准确性，还极大地提升了模型的稳定性和适应性。自监督学习方法也在医学图像异常检测中显示出巨大的潜力。这些方法通过设计预文本任务来学习图像的表达，然后用于异常检测。例如，Huang 等人^[9]提出了一种多级特征适应框架，用于将预训练的视觉-语言模型适应于医学图像异常检测。通过逐步增强不同层级的视觉特征来提高模型对异常的识别能力。这种方法在数据稀缺的情况下表现出色，能够有效利用未标注数据进行预训练，减少对标注数据的依赖。然而，深度学习检测技术在训练和优化过程中往往需要消耗很多的计算资源，这在实际应用中可能会带来一些限制。。

1.2.3 基于多模态视觉-语言模型的医学图像异常检测方法

随着大规模视觉-语言预训练模型的发展，研究人员开始探索如何将这些模型应用于医学图像异常检测，通过联合训练图像和文本表示，能够实现跨模态的理解和推理。例如，Radford 等人提出的 CLIP 模型^[10]，通过在大规模互联网图像-文本对上进行对比学习，能够学习到图像和文本之间的语义关联。这种跨模态的能力使得 CLIP 在多个视觉任务中表现出色，包括图像分类、目标检测和图像描述生成。在医学图像领域，研究者们尝试将 CLIP 模型适应于特定的医学任务。例如，Wang 等人提出的 MedCLIP^[11]，通过解耦图像和文本对，利用医疗知识来构建语义相似度矩阵，从而消除对比学习中的假负样本问题。这种方法通过引入医疗领域知识，提高了模型对医学图像的理解能力。此外，Huang 等人^[12]进一步提出了一个轻量级多级适应框架，用于将 CLIP 模型适应于医学图像异常检测。通过逐步增强不同层级的视觉特征来提高模型对异常的识别能力，使得模型能够更准确地定位和识别异常区域。




图 1-4 医学成像中的 CLIP 图示^[16]

为了充分利用多模态信息，研究者们还探索了图像和文本的融合策略。例如，Huang

等人提出的 GLoRIA 方法^[13]，通过建模医学图像和报告之间的全局和局部交互，捕捉特定图像区域的病理含义。这种方法能够更全面地理解和分析医学图像中的异常模式，提高了检测的准确性和鲁棒性。此外，Zhang 等人提出的 ConVIRT 方法^[14]，通过在配对的 X 射线图像和报告上进行双向对比学习，进一步提高了模型的表示能力。这些方法是将图像信息与文本信息融合，能够更精准地识别异常特征，尤其是在数据稀缺的情况下，通过跨模态的知识转移来提高模型的性能。

1.3 论文的主要内容与结构安排

1.3.1 本文的核心贡献与技术方案概览

针对传统医学图像异常检测方法的局限性以及大规模标注医学数据集的稀缺，本文提出基于深度学习与视觉语言模型的医学图像异常检测系统，研究架构如图 1-5。




图 1-5 基于视觉模型的医学图像异常检测系统研究架构

1.3.2 论文的组织架构与章节内容提要

本文聚焦于基于视觉模型的医学图像异常检测系统的设计与实现，各章节内容紧密相连且层层递进，具体组织架构与章节内容提要如下：

（1）第一章 研究背景

本章首先阐述医学图像异常检测的研究背景与意义，深入分析传统方法的局限性以及深度学习和视觉-语言模型为其带来的新突破。随后，系统梳理国内外在该领域的研究现状，涵盖基于传统图像处理、深度学习以及多模态视觉-语言模型的医学图像异常检测方法。最后，概括论文的核心贡献与技术方案，给出整体的组织架构与章节内容提要，使读者对全文有初步的整体性认识，为后续深入探讨奠定基础。

（2）第二章 相关理论基础

本章深入剖析视觉-语言模型的架构与原理，聚焦 CLIP 模型，详细阐述其通过对比学习实现图像和文本语义对齐的机制。分别对视觉编码器(Vision Transformer 网络模型)和文本编码器以及可学习文本提示进行解读，说明二者如何协同工作以提升模型对视觉与文本信息的理解和融合能力。此外，介绍适配器（包括分割适配器和分类适配器）在多模态信息处理中的关键作用及工作方式。对多级特征处理技术进行总述，涉及特征提取、选择和融合等环节，并详细讲解特征对齐和对比学习这两种在医学图像异常检测中极具价值的技术手段。最后，阐述实验指标与数据集，明确评价医学图像异常检测系统性能的各项指标以及常用的数据集资源，为后续实验验证提供有力支撑。

（3）第三章 基于改进 CLIP 的跨模态特征适配与识别

本章着重介绍基于改进 CLIP 的跨模态特征适配与识别方法。首先呈现总体框架，涵盖训练与测试两大阶段，详述各阶段的关键操作流程，凸显多层次视觉特征适配及跨模态对齐机制，以及 ATPrompt 文本提示学习方法的独特优势。然后分别对 CLIP 优化策略、医学图像特征的多层级语义映射、跨模态特征融合方法以及基于 ATPrompt 的可学习文本提示进行深入探讨，精准解析各部分的创新设计与技术细节，展现如何利用这些方法，可以显著增强模型在医学图像异常检测任务中的性能表现。

（4）第四章 医学图像异常检测系统设计与实现

本章详细描述医学图像异常检测系统的功能设计与实现过程。在功能设计方面，明确系统的各项功能模块及其相互关系，以图形界面为例，说明系统如何实现不同算法的医学图像异常检测效果的直观比较展示。在实现与测试部分，分别针对用户管理模块、检测模块、结果展示模块和评估模块，阐述其具体实现方式与实现效果，并依据严谨的测试方法和全面的测试用例，对各功能模块进行测试，最后得出系统的测试结论，证实系统具备良好的稳定性和准确性，能够满足用户对医学图像异常检测的实际需求。

（5）第五章 总结与展望

本章对本研究的主要发现与贡献进行系统总结，着重强调所提方法在跨模态特征适配和异常检测任务中的有效性，以及模型所具备的技术优势与实际应用价值。同时，展望未来模型的改进方向与潜在的扩展应用，为后续研究提供参考思路与前进方向，使读者对医学图像异常检测领域的未来发展有更清晰的认识。

2 相关理论基础

2.1 视觉—语言模型总述

视觉—语言模型近年来在多模态信息处理领域取得了显著进展，其核心目标是构建一个能够同时理解和处理视觉与文本信息的统一框架。这类模型通过联合训练图像和文本数据，学习到图像和文本之间的深层语义关联，从而实现跨模态的理解和推理。学习方法，将图像和文本分别编码至共享嵌入空间，通过最小化配对样本间距离并最大化未配对样本间距离，实现跨模态对齐。


在架构设计方面，现代视觉—语言模型逐渐从独立训练视觉和语言组件，转向以预训练大型语言模型（LLMs）为骨干的融合架构。Med-VLM^[21]通过在医学图像数据上微调预训练的 LLM，并引入视觉编码器提取图像特征，实现了视觉与语言信息的高效融合，支持从异常检测到诊断推理等多种下游任务。

为适应医学图像领域的特殊需求，视觉—语言模型的训练方法也在不断创新。对比学习仍是预训练阶段的核心方法，例如 Medical-CLIP^[22]在对比学习框架下，利用大规模医学图像数据学习鲁棒的视觉表示。此外，自监督学习方法如掩码图像建模任务也被引入，例如通过预测医学图像中被掩码区域的视觉特征，模型能够学习到更为细致的医学图像语义信息。

2.1.1 CLIP 模型的架构

CLIP 模型是一种新颖的视觉-语言模型，它通过对比学习将图像和文本映射到一个共享的语义空间，从而实现跨模态的理解和生成。该模型的架构主要由图像编码器和文本编码器两个关键组件构成。图像编码器基于 Vision Transformer 或深度卷积神经网络，将图像数据转化为高维特征表示；文本编码器则基于 Transformer 架构，处理自然语言文本生成文本特征嵌入^[10]。通过联合训练，CLIP 使图像和文本特征在嵌入空间中实现语义对齐。采用对比损失函数，通过缩小正样本对的距离并扩大负样本对的距离，使模型学习到图像和文本间的语义关联^[10]。

如下图 2-1 所示，CLIP 的训练数据集包含大量的互联网图像-文本对。借助对比学习，CLIP 能捕捉图像和文本的语义关联，在多种下游任务中展现出强大的零样本学习能力。例如，在图像分类任务中，CLIP 可结合文本提示实现零样本预测。此外，CLIP 的多尺度特征提取能力使其在图像异常检测等任务中具有显著优势，能够同时捕捉图像的全局和局部特征^[13]。

图 2-1 MedCLIP 模型架构图^[13]

CLIP 架构不仅在自然图像领域取得了显著成果，还为医学图像处理提供了新思路。MedCLIP 模型通过引入医学图像和文本的对比学习，优化了 CLIP 在医学领域的应用，展示了其在医学图像分类和异常检测中的潜力^[11]。GLoRIA 模型通过全局和局部特征的联合学习，增强了 CLIP 架构在医学图像识别中的标签效率，证明了其在处理复杂医学图像数据时的有效性^[13]。ConVIRT 模型则利用对比学习进行视觉-语言表示学习，为医学图像的多模态理解提供了新思路^[14]。这些模型都基于 CLIP 架构进行了拓展和优化，充分发挥了 CLIP 在特征提取和语义对齐方面的优势，以更好地适应医学图像领域的特殊需求。CLIP 架构的灵活性和扩展性使其成为视觉-语言模型领域的重要里程碑，为后续研究和应用提供了坚实基础^[10]。

2.1.2 视觉编码器: Vision Transformer 网络模型

近年来，Transformer 模型凭借其在自然图像和语言处理中取得的杰出成就在计算机视觉领域备受瞩目。Vision Transformer (ViT)^[17]的诞生，开启了一种全新的趋势，它能够直接从图像中提取出卓越的特征。与传统卷积神经网络不同，ViT 放弃了局部性和平移不变性这两个先验假设。局部性假设认为图像中相邻区域的特征是相似的，而平移不变性则假设图像的平移操作不会影响其卷积特征。然而，由于舍弃了这些先验假设，ViT 在训练过程中需要依赖大规模数据集来克服这些限制，进而达成卓越的性能表现。

如图 2-2 所示，ViT 将图像划分为固定尺寸的 patches，每个 patch 通过线性嵌入的方式被映射到一个高维空间之中。这些嵌入向量会与位置嵌入相融合，以此保留空间信息，并被输入至标准的 Transformer 编码器进行处理。ViT 在序列起始处引入了一个可学习的“分类”嵌入，该嵌入在 Transformer 编码器输出时，充当图像的代表。这一设计借鉴了自然语言处理领域中 BERT 模型的“[class]”标记，专门用于图像分类任务。




图 2-2 Vision Transformer 模型结构图^[17]

ViT 的核心优势在于其简洁的模型架构，尽可能地减少了图像特定的归纳偏置引入。除了最初的图像分割步骤外，其余处理流程均采用了标准的 Transformer 架构。在预训练阶段，ViT 选用 Adam 优化器；而到了微调阶段，则改用 SGD 优化器。ViT 还具备出色的灵活性和适应性，当处理更高分辨率的图像时，它能够对预训练的位置嵌入进行插值，从而适应不同分辨率的图像输入。正是由于这些特性，使得 ViT 在图像分类任务中表现出了强大的性能。尤其在大规模数据集上完成预训练之后，其还能有效地迁移到那些数据量相对较少的任务中，展现出了良好的泛化能力。

2.1.3 文本编码器与可学习文本提示

文本编码器是视觉—语言模型的关键组成部分，其核心作用是将自然语言文本转换为语义特征向量，以便与视觉特征进行有效的融合和比较。文本编码器通常基于 Transformer 架构^[18]，该架构通过自注意力机制捕捉文本中单词之间的长距离依赖关系，动态地关注文本中的重要信息，生成具有丰富语义的文本特征向量。自注意力机制的计算公式如下：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中， Q 、 K 、 V 分别是查询矩阵、键矩阵和值矩阵， d_k 是键的维度。通过这种方式，Transformer 架构能够动态地关注文本中的重要信息，生成具有丰富语义的文本特征向量。

在视觉—语言模型中，文本编码器通常与视觉编码器协同工作。视觉编码器将图像转换为高维特征向量，而文本编码器则将文本描述映射到相同的特征空间。CLIP 模型通过联合训练图像和文本特征，使得图像和文本能够在同一语义空间中进行比较和融合。

这种设计提高了模型对图像和文本的理解能力，同时使得模型能够适应多种下游任务。

然而，在特定领域，如医学图像中，直接使用通用的预训练文本编码器可能无法充分利用领域特定的知识，从而影响模型的性能。为了解决这一问题，可学习文本提示（Learnable Text Prompts）被引入到视觉—语言模型中。可学习文本提示通过在特定任务上进行微调，自适应地调整文本特征，使其能够更好地匹配视觉特征并适应特定领域的语义需求。Huang 等人提出的方法^[9]在医学图像异常检测任务中，可学习文本提示可以根据医学图像中的异常模式动态生成相应的文本描述，从而提高模型对异常的识别能力。

可学习文本提示通常由一组可学习的嵌入向量组成，这些向量可以与预训练文本编码器的输入相结合，以生成特定任务的文本表示。例如，Zhang 提出了一种基于可学习文本提示的方法^[16]，通过优化以下目标函数来训练提示：

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda \mathcal{L}_{\text{box}} \quad (2-2)$$

$\mathcal{L}_{\text{cls}}$ 是分类损失，用于衡量预测类别与真实类别之间的差异； $\mathcal{L}_{\text{box}}$ 是边界框回归损失，用于定位图像中的目标区域； λ 是平衡两个损失的权重参数。

可学习文本提示还能够减少人工设计文本提示的复杂性，提高模型的灵活性和通用性。Zhang 等人提出的 ConVIRT 方法^[16]通过将可学习文本提示与视觉编码器相结合，模型能够在训练过程中自动学习到更有效的文本特征表示，进而提升视觉—语言模型在医学图像分析等复杂任务中的性能。Wang 等人提出的 MedCLIP 方法^[11]通过对比学习从非配对的医学图像和文本中提取信息，有效地解决了医学图像数据稀缺的问题，并在多种医学图像分类任务中表现出优异的性能。在 MedCLIP 中，文本编码器使用 BioClinicalBERT 作为基础，该模型在生物医学领域文本数据上进行了预训练，能够更好地捕捉医学文本的语义信息。Huang 等人提出的方法^[13]通过这种方式，MedCLIP 实现了对医学图像和文本的高效联合表示，从而在医学图像分类任务中取得了显著的性能提升。

2.2 适配器

在现代视觉语言模型领域，适配器（Adapter）作为一种轻量级的微调策略，扮演着至关重要的角色。其核心目标是在不破坏预训练模型原有架构的基础上，显著提升模型在特定任务中的性能表现。适配器的设计理念是通过引入小型参数化的变换层，对输入特征进行调整，以使其更好地契合新的任务需求。这种策略不仅能够有效减少计算资源的消耗，还能在保持预训练模型泛化能力的同时，增强模型对特定任务的适应性。根据应用场景的不同，适配器主要分为分割适配器和分类适配器。分割适配器专注于图像分割任务，通过优化特征表示来提高分割精度；而分类适配器则侧重于图像分类任务，提升模型对不同类别图像的识别能力。这两种适配器在医学图像异常检测领域均具有重要的应用价值，能够在不同的医学图像分析任务中发挥关键作用。

2.2.1 分割适配器

分割适配器主要致力于解决图像分割任务中的多模态信息融合难题。具体而言，它借助双向交互机制，显著增强图像与语言特征之间的融合效果。假设输入特征为 X ，适配器首先通过一个简单的线性变换对输入特征进行初步调整，该变换可表示为：

$$A(X) = XW_1 + b_1 \quad (2-2)$$

其中， W_1 和 b_1 分别代表需要学习的权重矩阵与偏置向量。这一线性变换的目的是通过学习适当的权重和偏置，将输入特征映射到一个新的特征空间，从而为后续的非线性变换提供基础。为了进一步提升模型的非线性表达能力，通常会在变换后引入激活函数，如 ReLU：

$$Y = \sigma(A(X)) \quad (2-3)$$

在此， σ 表示激活函数，如 ReLU。激活函数的引入旨在为模型引入非线性特性，使模型能够捕捉到输入特征中更复杂的模式和关系。经过激活函数的非线性变换，特征的表达能力显著提升，进而能够更好地满足分割任务的要求。

在实际应用中，分割适配器不仅局限于单层变换，还可采用多层感知机（MLP）的形式，以进一步增强模型的表现力。对于每层 MLP，其定义如下：

$$Y_i = \sigma(W_i Y_{i-1} + b_i) \quad (2-4)$$

其中， i 表示 MLP 的层数， $Y_0 = X$ 为初始输入特征。这种多层结构允许模型逐步学习更高级别的特征表示，每一层的输出都作为下一层的输入，通过逐层的非线性变换，模型能够捕捉到输入特征中更深层次的语义信息。通过这种方式，适配器能够有效地调整输入特征，以适应不同分割任务的特定需求。

此外，适配器还可与注意力机制相结合，以捕捉全局上下文信息。例如，Lee 等人 [2023]提出了一种文本引导的跨位置注意力机制，该机制通过计算不同位置之间的相似度，显著增强了特征对齐的效果。具体公式如下：

$$S_{ij} = \frac{\exp(\text{sim}(F_i, F_j)/\tau)}{\sum_k \exp(\text{sim}(F_i, F_k)/\tau)} \quad (2-5)$$

在此， S_{ij} 表示第 i 个位置与第 j 个位置之间的相似度得分， τ 为温度参数，用于调节分布的尖锐度，而 $\text{sim}(\cdot)$ 则表示两个特征向量之间的相似度函数。通过计算不同位置之间的相似度，注意力机制能够动态地调整特征的权重，使模型更加关注与当前任务相关的特征部分，从而进一步提升分割任务的精度。通过这种方式，适配器在保持原始模型结构不变的前提下，显著提升了分割任务的精度。

2.2.2 分类适配器

分类适配器则主要应用于图像分类任务中的特征调整。与分割适配器不同，分类适配器更侧重于如何通过少量可训练参数来优化模型在新任务上的表现。分类适配器的核

心在于特征投影，即将高维特征映射到低维空间中进行分类。假设输入特征为 X ，分类适配器可表示为：

$$P(X) = XW_p + b_p \quad (2-6)$$

其中， W_p 和 b_p 分别代表需要学习的投影矩阵与偏置向量。这一投影操作的目的是将输入特征从原始的高维空间映射到一个更适合分类的低维空间，在这个低维空间中，特征的类别区分度更高，从而有助于提高分类的准确性。为了进一步提高分类的准确性，通常还会引入归一化层，如 Batch Normalization 或 Layer Normalization，以稳定训练过程中的梯度流动。具体公式如下：

$$Z = \text{Norm}(P(X)) \quad (2-7)$$

在此， $\text{Norm}(\cdot)$ 表示归一化操作。归一化层的作用是调整特征的分布，使其具有零均值和单位方差，从而稳定训练过程中的梯度流动，避免梯度爆炸或消失的问题。通过归一化操作，模型的训练更加稳定，收敛速度更快，分类性能也得到显著提升。最终的分类输出则可通过 Softmax 函数计算得到：

$$O = \text{Softmax}(Z) \quad (2-8)$$

O 表示每个类别的预测概率分布。Softmax 函数的作用是将归一化后的特征映射到一个概率分布上，每个类别的预测概率表示该类别在当前输入特征下的置信度。通过这种方式，分类适配器在保持模型复杂度不变的情况下，显著提升了分类任务的性能。

2.3 多级特征处理技术总述

多级特征处理技术是指对不同层次的特征进行整合与优化的过程，这对于提高医学图像分析中的精度至关重要。这类技术主要包括特征提取、特征选择以及特征融合等多个环节。首先，在特征提取阶段，利用深度卷积神经网络（CNN）或 Transformer 架构从原始数据中抽取多层次特征。例如，Dosovitskiy 等人^[17]提出的 ViT 模型通过自注意力机制有效地捕捉了长距离依赖关系，从而增强了特征表示能力。具体来说，假设输入图像为 I ，经过若干层 Transformer 编码器后得到特征表示 $F = \text{Encoder}(I)$ ，其中每个编码层可以表示为：

$$F_i = \text{SelfAttention}(F_{i-1}) + \text{MLP}(F_{i-1}) \quad (2-9)$$

在此， $\text{SelfAttention}(\cdot)$ 和 $\text{MLP}(\cdot)$ 分别代表自注意力机制和多层感知机。自注意力机制使模型能够动态地关注输入特征中的重要部分，而多层感知机则进一步对特征进行非线性变换，从而增强特征的表达能力。接着，在特征选择过程中，根据特定标准筛选出最具代表性的特征。这一步骤可以通过计算特征的重要性得分来实现，如使用 Grad-CAM 方法来定位关键区域。最后，通过特征融合将多尺度信息结合起来，形成更全面的表征。例如，Zhong 等人^[4]提出了一种 GuideDecoder 模块，该模块能够有效地融合多模态信息，并生成精确的分割结果。

2.3.1 特征对齐

特征对齐是一种确保来自不同模态的数据能够在相同维度上进行比较的技术。对于医学图像分析而言，这通常涉及到将图像特征与文本描述进行对齐。具体做法包括使用交叉注意力机制捕捉全局上下文信息，并将其应用于特征空间中。例如，Zhou 等人提出的 RegionCLIP 方法，通过区域级别的语言-图像预训练实现了这一目标。在特征对齐过程中，首先需要定义一个相似度函数来衡量两个特征向量之间的匹配程度。假设图像特征为 F_I ，文本特征为 F_T ，则它们之间的相似度可以通过余弦相似度计算：

$$S(F_I, F_T) = \frac{F_I \cdot F_T}{\|F_I\| \|F_T\|} \quad (2-10)$$

余弦相似度，是一种广泛使用的相似度量化方法，通过计算两个向量之间的夹角余弦值来评估它们的相似性。为了进一步提升对齐效果，可以引入对比学习策略。例如，InfoNCE 损失函数被广泛应用于特征对齐任务中，其公式如下：

$$L_{InfoNCE} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_k \exp(\text{sim}(z_i, z_k)/\tau)} \quad (2-11)$$

在此， z_i 和 z_j 分别是正样本对的特征表示，而 τ 是一个温度参数，用于调节分布的尖锐度。通过这种方式，模型能够学习到更加稳健的特征表示，从而提高异常检测的准确性。此外，Chen 等人的研究表明，通过对齐不同模态的特征，可以显著提升跨模态任务的表现。

2.3.2 对比学习

对比学习是一种自我监督学习策略，主要用于增强模型对数据内在结构的理解。在医学图像领域，这种方法可以帮助模型更好地识别正常与异常模式。通过最大化正样本对之间的相似度同时最小化负样本对之间的相似度来训练模型，可以显著提升模型的鲁棒性和泛化能力。具体实现时，首先构建一批包含正负样本对的数据集，然后定义一个损失函数来量化模型预测与实际标签之间的差异。例如，Chen 等人提出的方法采用了 InfoNCE 损失函数，该损失函数不仅适用于图像分类任务，也可用于医学图像中的异常检测。假设输入特征为 X ，通过对比学习，我们可以定义一个对比损失函数：

$$L_{Contrastive} = -\log \frac{\exp(\text{sim}(x_i, x_j^+)/\tau)}{\sum_k \exp(\text{sim}(x_i, x_k^-)/\tau)} \quad (2-12)$$

在此， x_i 是锚点样本， x_j^+ 是正样本，而 x_k^- 是负样本。温度参数 τ 用于调节分布的尖锐度。通过这种方式，模型能够学习到更加鲁棒的特征表示，从而提高异常检测的准确性。此外，Wang 等人^[1]提出了 MedCLIP 方法，通过对比学习从未配对的医学图像和文本中学习有效的视觉语言表示。实验结果表明，对比学习不仅能提升模型在零样本设置下的表现，还能有效应对数据标注不足的问题。

2.4 实验指标与数据集

2.4.1 评价指标

在医学图像异常检测系统的设计与实现中, 选择合适的评价指标对于评估模型性能至关重要。常用的评价指标包括 Dice 系数、Jaccard 指数 (IoU)、准确率 (Accuracy)、召回率 (Recall)、F1 分数以及 AUC (Area Under the Curve)。这些指标分别适用于不同的任务需求, 并能够全面反映模型的综合表现。

Dice 系数和 Jaccard 指数常用于评估分割任务的效果。Dice 系数衡量了预测结果与真实标签之间的重叠程度, 其值越接近 1, 表明模型的分割效果越好。具体公式如下:

$$\text{Dice} = \frac{2|X \cap Y|}{|X| + |Y|} \quad (2-13)$$

其中, X 和 Y 分别表示预测结果和真实标签的二值化区域。Dice 系数通过计算预测区域与真实区域的交集与并集的比例, 提供了一个量化评估分割精度的指标。

Jaccard 指数 (IoU) 是另一种衡量重叠程度的指标, 定义为交集面积除以并集面积。通过交集与并集的比例来评估分割效果, 其值域为 0,1, 值越接近 1 表示分割结果与真实标签的重合度越高。Dice 系数和 Jaccard 指数都是用于评估分割任务的常用指标, 它们能够有效地衡量模型在不同数据集上的分割精度:

$$\text{IoU} = \frac{|X \cap Y|}{|X \cup Y|} \quad (2-14)$$

准确率、召回率和 F1 分数主要用于分类任务中的性能评估。准确率衡量了模型正确分类样本的比例, 计算公式为:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}} \quad (2-15)$$

其中, TP、TN、FP 和 FN 分别代表真阳性、真阴性、假阳性和假阴性。准确率是一个直观的指标, 表示模型整体分类正确的比例, 但在类别不平衡的数据集中可能不够敏感。

召回率 (也称为敏感度或 True Positive Rate, TPR) 衡量了实际正类被正确识别的比例, 召回率关注的是模型对正类的识别能力, 特别是在医学图像异常检测中, 高召回率意味着模型能够较好地识别出异常样本, 减少漏检的可能性:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2-16)$$

F1 分数是准确率和召回率的调和平均数, 能够综合反映模型的分类能力:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2-17)$$

其中, 精确率 (Precision) 定义为:

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2-18)$$

精确率衡量的是模型预测为正类的样本中实际为正类的比例。F1 分数结合精确率与召回率, 能够平衡模型的精确性和召回能力, 是综合评估分类性能的关键指标。准确率、召回率和 F1 分数是分类任务中常用的评价指标, 它们有助于我们了解模型在不同类别上的表现, 尤其在处理不平衡数据集时具有重要意义。

AUC (Area Under the Curve) 即 ROC 曲线所围成的面积, 用于衡量分类模型的整体

体效能。其取值介于 0 与 1 之间，数值越趋近于 1，表明模型的分类性能越出色。具体来说，AUC 衡量了模型区分正负样本的能力，即在所有可能的阈值下，模型将正样本排在负样本前面的概率。

假设模型输出的预测概率为 P ，真实标签为 Y ，则可以通过以下步骤计算 AUC。根据模型输出得到每个样本的预测概率。将预测概率从小到大排序，逐步调整阈值，计算各个不同阈值下的 TPR（True Positive Rate）以及 FPR（False Positive Rate），同时可以绘制 ROC 曲线来表述。TPR 和 FPR 的计算公式分别为：

$$TPR = \frac{TP}{TP + FN} \quad (2-19)$$

$$FPR = \frac{FP}{FP + TN} \quad (2-20)$$

计算 AUC：通过数值积分或梯形法计算 ROC 曲线下的面积。具体来说，可以使用梯形法公式来近似计算 AUC：

$$AUC = \sum_{i=1}^{n-1} (x_{i+1} - x_i) \cdot \frac{(y_{i+1} + y_i)}{2} \quad (2-21)$$

其中， x_i 和 y_i 分别是第 i 个点的 FPR 和 TPR 值。AUC 作为一个综合评估指标，能够有效衡量模型在不同阈值下的分类性能，特别是在处理不平衡数据集时，AUC 能够提供更全面的性能评估。

2.4.2 多模态数据集

随着人工智能技术的迅猛发展，聚焦于特定解剖结构或疾病的医学图像分析领域，愈发凸显出数据集的重要性。数据集作为该领域发展的基石，对于推动算法研究以及临床应用的拓展具有不可替代的关键作用。专注于特定解剖结构或疾病的多模态医学图像数据集不断涌现，为研究人员提供了极为宝贵的资源。这些数据集不仅覆盖了从常见器官到特定病理的广泛范围，还涵盖了多种成像模式，如 CT、MRI、X 光和超声等。此外，许多数据集还结合了文本描述、临床报告和其他形式的元数据，进一步增强了其在跨模态学习和特征对齐方面的价值，为多模态医学图像分析提供了坚实的基础。

近年来，医学图像数据集的发展呈现出多样化和专业化的特点。一方面，数据集的规模不断扩大，包含更多的样本和更丰富的标注信息，这为模型训练提供了更充足的数据支持，有助于提升模型的泛化能力和鲁棒性；另一方面，针对特定疾病或解剖区域的专业化数据集也层出不穷，为解决特定医学问题提供了有力支持。这些数据集不仅有助于提升模型的准确性和鲁棒性不仅得到了提升，还推动了医学图像处理技术在临床实践中的广泛应用。在医学图像分割领域、诊断和治疗规划等领域，有多种多模态数据集具有重要意义。它们各自针对不同的医学挑战，提供了丰富的图像数据和精确的标注信息，推动了医学图像处理技术的发展和临床应用的创新。这些数据集不仅涵盖了常见的成像方式，还包括了文本与图像的联合数据，适用于广泛的医学图像分析任务，为研究人员提供了丰富的研究素材。医学图像常用公开数据集如下表 2-1 所示：

表 2-1 医学图像常用公开数据集

数据集	模态	解剖区域	解剖结构	类别	数据量
PMC-CLIP	文本+图像	多样	多样	正常/异常	50,000
OCOV2 Radiology	图像	胸部	肺	正常/异常	30,000
UniMed-CLIP	文本+图像	多样	多样	正常/异常	40,000
CheXpert-v1.0	图像	胸部	肺	14 种疾病标签	224,316
MIMIC-CXR	图像	胸部	肺	多种疾病标签	377,110
OpenI	图像	胸部	肺	正常/异常	7,470
ChestX-ray8	图像	胸部	肺	8 种疾病标签	112,120
RadImageNet	图像	多样	多样	正常/异常	1,000,000
Retinal-Dataset	图像	眼睛	视网膜	正常/病变	12,000
Quilt-1M	图像	多样	多样	正常/异常	1,000,000

2.4.3 相似度计算

在医学图像分析领域，相似度计算是评估多模态特征对齐效果的重要手段。通过精确计算不同模态数据之间的相似度，可以有效地提升模型在跨模态任务中的表现，例如医学图像分类、异常检测和分割等任务。本节将详细讨论几种常用的相似度计算方法及其在医学图像分析中的应用。

相似度计算的基本思想是衡量两个特征向量之间的距离或相似程度。以下是几种常见的相似度计算方法及其数学表达式的详细解释：

余弦相似度是一种常用的距离度量方法，特别适用于高维空间中的特征向量比较。它们的相似性是通过计算两个向量之间的夹角的余弦值。参考公式为：

$$\text{sim}(a, b) = \frac{a \cdot b}{\|a\| \|b\|} \quad (2-22)$$

其中， a 和 b 是两个特征向量， $\|a\|$ 和 $\|b\|$ 分别是它们的欧几里得范数。而余弦相似度的取值范围为 $[-1, 1]$ ，其中值越靠近 1 表示这两个向量越相似。这种方法在处理高维数据时表现出色，因为它主要关注向量的方向而非其大小。

欧氏距离是另一种常见的相似度度量方法，它通过计算两个向量之间的直线距离来衡量它们的差异。具体公式为：

$$d(a, b) = \sqrt{\sum_{i=1}^n (a_i - b_i)^2} \quad (2-23)$$

欧氏距离越小，表示两个向量越相似。这种方法直观地反映了向量之间的实际距离，适用于各种类型的特征向量。

曼哈顿距离（也称为 L1 距离）是通过计算两个向量之间各维度差值的绝对值之和来衡量它们的差异。具体公式为：

$$d(a, b) = \sum_{i=1}^n |a_i - b_i| \quad (2-24)$$

曼哈顿距离同样越小，表示两个向量越相似。这种方法在处理具有不同量纲的特征时表现出色，因为它对异常值的敏感度较低。

Jaccard 相似系数主要用于二值化特征向量之间的相似度计算。它通过计算两个集合的交集与并集的比例来衡量相似性。具体公式为：

$$\text{Jaccard}(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (2-25)$$

其中，A 和 B 是两个二值化特征向量。Jaccard 相似系数的取值范围为[0,1]，值越接近 1 表示两个向量越相似。这种方法特别适用于处理稀疏数据，因为它只关注非零元素的交集和并集。

3 基于改进 CLIP 的跨模态特征适配与识别

3.1 总体框架

本文提出的模型架构涵盖训练与测试两大阶段，整体框架如图 3-1 所示。该架构整合了多层次视觉特征适配及跨模态对齐机制，并引入一种名为 ATPrompt 的新型文本提示学习方法。




图 3-1 用于医学图像异常检测的跨模态特征适配与识别模型

在训练阶段，医学图像被输入基于 CLIP 的视觉编码器以提取多层次视觉特征。在视觉编码器的不同层级插入残差适配器，用来弥合自然图像与医学图像间的领域差异，这些适配器逐步优化视觉特征，助力模型更高效地捕捉医学图像的语义信息。适配器经训练后，通过最小化多层次像素级视觉-文本特征对齐损失函数来重新校准视觉特征，引导模型聚焦异常识别，而不仅限于物体语义层面。

首先采用 ATPrompt 生成文本特征。与传统依赖类别令牌的文本提示不同，ATPrompt 在可学习软提示中融入通用属性令牌，使文本提示从以类别为中心的形式转变为属性-类别混合形式。通过可微分属性搜索方法，从大型语言模型构建的候选池中甄别出代表性属性，生成的文本特征更具表现力，且能与医学图像的视觉特征更好地对齐，尤其针对未见类别。

视觉特征与文本特征经多层级像素级特征对齐后，进一步优化。在每个特征层级，利用 Dice 损失、焦点损失及二元交叉熵损失的组合，对适配后的视觉特征与文本特征进行比较，确保模型在不同语义层级上学习视觉模式与文本描述的关联，强化模型对未见医学成像模态及解剖区域的泛化能力。

在测试阶段，待测医学图像经同一视觉编码器和适配器处理后，获取多层级视觉特征。这些特征分别与 ATPrompt 生成的正常及异常类别文本提示特征对比，计算相似性度量，得出图像在不同层级上属于正常或异常类别的得分。与此同时，模型运用多分支结构，包含零样本分支与少样本分支。零样本分支仅依据文本特征预测，少样本分支则借助少量标记的正常图像特征构建特征记忆库，通过与记忆库特征相似性搜索辅助预测。两个分支的预测结果经加权融合策略整合，输出图像级和像素级异常检测的最终结果。

整体框架旨在应对零样本和少样本医学异常检测挑战，融合多层级特征适配与跨模态对齐优势，既提升模型在多样化医学数据类型上的泛化能力，又保持在有限标记数据时的灵活性。ATPrompt 的集成进一步提升文本特征的表现力和与视觉特征的对齐性，使模型在医学异常检测任务中更具鲁棒性和有效性。

3.1.1 CLIP 优化策略

本文对 CLIP 模型进行了针对性优化，用来提升 CLIP 模型在医学图像异常检测任务中的性能。通过在 CLIP 的视觉编码器中引入多级残差适配器，增强模型对医学图像特征的提取能力。这些适配器能够逐步优化视觉特征，使模型能够更有效地捕捉医学图像中的异常信息。在视觉编码器的第 l 层，特征适配通过以下公式实现：

$$F_{\text{adapted}}^{(l)} = \text{Adapter}^{(l)}(F_{\text{original}}^{(l)}) \quad (3-1)$$

其中， $F_{\text{original}}^{(l)}$ 表示原始视觉特征， $\text{Adapter}^{(l)}$ 表示第 l 层的适配器， $F_{\text{adapted}}^{(l)}$ 表示优化后的视觉特征。适配器由两个线性变换组成，具体表示为：

$$\text{Adapter}^{(l)}(F) = \text{ReLU}(W_1^{(l)}F)W_2^{(l)} \quad (3-2)$$

其中， $W_1^{(l)}$ 和 $W_2^{(l)}$ 是适配器的可学习参数。为了保留原始特征信息，适配过程中引入了残差连接：

$$F_{\text{final}}^{(l)} = \gamma F_{\text{adapted}}^{(l)} + (1 - \gamma) F_{\text{original}}^{(l)} \quad (3-3)$$

其中， γ 是残差比例系数，用于控制原始特征和优化特征的融合程度。

此外，为了使视觉特征能够更好地与文本特征对齐，本文对视觉-文本特征对齐过程进行了优化。在训练阶段，通过最小化多层级像素级视觉-文本特征对齐损失函数来优化模型参数。损失函数由 Dice 损失、焦点损失（focal loss）和二元交叉熵损失组成，其组合形式为：

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{Dice}} + \lambda_2 \mathcal{L}_{\text{Focal}} + \lambda_3 \mathcal{L}_{\text{BCE}} \quad (3-4)$$

其中， λ_1 、 λ_2 和 λ_3 是损失权重系数，分别控制 Dice 损失、焦点损失和二元交叉熵损失的影响。这种多损失函数的组合能够确保模型在不同语义层级上学习视觉模式与

文本描述的关联，从而增强模型对未见医学成像模态及解剖区域的泛化能力。

3.1.2 医学图像特征的多层级语义映射

为了实现医学图像特征的多层级语义映射，本文提出了一种层次化的特征提取与映射策略。该策略旨在从不同语义层级提取医学图像的特征，并将其映射到与文本特征可比较的共享语义空间，以便更好地进行跨模态特征对齐和异常检测。

(1) 层次化特征提取

医学图像包含丰富的多尺度信息，从低层的边缘、纹理特征到高层的解剖结构和病灶模式。为了捕捉这些不同层次的语义信息，本文采用了基于 CLIP 的视觉编码器，并在其不同层级提取特征。视觉编码器将输入图像逐步转化为不同层级的特征图，每一层都包含不同尺度和语义层次的信息。第 1 层的特征图可以表示为：

$$F^{(1)} = \text{VisualEncoder}^{(1)}(I) \quad (3-5)$$

其中， I 表示输入的医学图像， $F^{(1)}$ 是第 1 层提取到的特征图。

(2) 特征语义增强

为了增强特征的语义表达能力，本文在每个特征层级应用特征语义增强模块。该模块通过结合局部和全局特征来丰富特征的语义信息。对于每个特征图 $F^{(l)}$ ，使用多尺度卷积操作提取局部特征，并通过注意力机制聚合全局特征。增强后的特征表示为：

$$F_{\text{enhanced}}^{(l)} = \text{SemanticEnhancer}^{(l)}(F^{(l)}) \quad (3-6)$$

其中， $\text{SemanticEnhancer}^{(l)}$ 表示第 l 层的特征语义增强模块。

(3) 特征映射到共享语义空间

为了使视觉特征和文本特征能够在同一语义空间进行比较，本文使用多层感知机 (MLP) 将视觉特征映射到与文本特征相同的语义空间。对于每个增强后的特征 $F_{\text{enhanced}}^{(l)}$ ，通过以下公式将其映射到共享语义空间：

$$F_{\text{mapped}}^{(l)} = \text{MLP}^{(l)}(F_{\text{enhanced}}^{(l)}) \quad (3-7)$$

其中， $\text{MLP}^{(l)}$ 表示第 l 层的多层感知机。

(4) 多层级特征融合

在将不同层级的特征映射到共享语义空间后，本文采用特征融合策略来整合这些特征。使用加权融合方法将不同层级的特征进行融合，以生成综合特征表示。融合后的特征表示为：

$$F_{\text{fused}} = \sum_{l=1}^L w^{(l)} F_{\text{mapped}}^{(l)} \quad (3-8)$$

其中， $w^{(l)}$ 表示第 l 层特征的权重， L 是特征层级的总数。这些权重可以通过训练过程学习得到，以确保融合后的特征能够更好地表示医学图像的语义信息。

3.1.3 跨模态特征融合方法

为了实现视觉特征与文本特征的有效融合,本文提出了一种多层级的跨模态特征融合策略。该策略能够在不同语义层级上逐步对齐视觉特征和文本特征,从而增强模型对医学图像异常的识别能力。

(1) 特征对齐与融合

在特征提取和映射之后,本文将视觉特征和文本特征进行对齐和融合。对于每个特征层级 l , 将映射后的视觉特征 $F_{\text{mapped}}^{(l)}$ 与文本特征 $T^{(l)}$ 进行逐元素加权融合:

$$F_{\text{fused}}^{(l)} = \alpha^{(l)} F_{\text{mapped}}^{(l)} + (1 - \alpha^{(l)}) T^{(l)} \quad (3-9)$$

其中, $\alpha^{(l)}$ 是该层的融合权重, 用于控制视觉特征和文本特征的贡献比例。这些权重通过训练过程学习得到, 以确保融合后的特征能够更好地反映图像和文本的共同语义信息。

(2) 双分支特征融合架构

为了更好地适应零样本和少样本学习场景, 本文设计了一种双分支特征融合架构。该架构包括零样本分支和少样本分支, 分别处理不同监督信息下的特征融合。

在零样本分支中, 仅利用文本特征进行特征融合。这对于未见类别的异常检测尤为重要, 因为它允许模型基于文本描述对未见类别进行预测。

在少样本分支中, 结合少量标记的正常图像特征构建特征记忆库。通过与记忆库中的特征进行相似性搜索, 模型能够利用有限的监督信息来增强对特定医学场景的适应能力。

(3) 融合特征的逐层优化

在特征融合之后, 本文通过逐层优化进一步提升特征的表达能力。使用轻量级的特征优化模块对融合后的特征进行处理:

$$F_{\text{optimized}}^{(l)} = \text{Optimizer}^{(l)}(F_{\text{fused}}^{(l)}) \quad (3-10)$$

其中, $\text{Optimizer}^{(l)}$ 是第 l 层的特征优化模块。该模块通常包含几个轻量级的卷积层和注意力机制, 用于增强特征的判别力。经过多层级的特征融合和优化, 本文得到最终的特征表示:

$$F_{\text{final}} = \sum_{l=1}^L w^{(l)} F_{\text{optimized}}^{(l)} \quad (3-11)$$

其中, $w^{(l)}$ 是第 l 层特征的权重, 这些权重通过训练学习得到, 以确保最终特征表示能够综合各层的信息, 为异常检测提供最有力的支持。

3.1.4 基于 ATPrompt 的可学习文本提示

在跨模态医学图像异常检测框架中, 文本提示模块对引导模型精准定位与识别异常模式至关重要。传统文本提示依赖人工设计模板, 存在语义表达局限和对医学图像异常特征描述不足的问题。为此, 本文引入 ATPrompt 方法, 通过学习优化文本提示, 使其更契合医学图像异常检测需求。

ATPrompt 的核心在于引入属性嵌入机制，将通用属性融入可学习的文本提示中。这些属性作为图像与文本对齐的中间桥梁，帮助文本提示关联到图像的视觉特征。ATPrompt 将文本提示构造成融合类别信息和属性信息的形式，使文本特征能够更精准地表达图像语义。文本提示的形式如下：

$$P = [\text{Learn Soft Token}_1, \dots, \text{Learn Soft Token}_M, \text{Class Token}, \text{Attr Token}_1, \dots, \text{Attr Token}_N] \quad (3-12)$$

其中， M 和 N 分别表示软提示令牌和属性令牌的数量。这些令牌在训练过程中通过反向传播算法进行学习更新。

为了确定最能代表医学图像特征的属性，本文设计了可微分属性搜索方法。该方法基于大型语言模型生成候选属性集合，通过学习选择最适合的属性组合。在训练过程中，属性搜索方法与文本提示学习联合优化，以提升文本提示质量和异常检测性能。属性搜索过程可表述为：

$$\mathcal{A} = \{a_1, a_2, \dots, a_K\} \quad (3-13)$$

$$\mathcal{S} = \{s_1, s_2, \dots, s_L\} \quad (3-14)$$

$$\text{Optimal Attributes} = \arg \max \mathcal{L}(\mathcal{A}, \mathcal{S}) \quad (3-15)$$

其中， $\mathcal{A}$ 是候选属性集合， $\mathcal{S}$ 是属性组合， $\mathcal{L}$ 是用于评估属性组合对齐效果的损失函数。为了使属性搜索过程可微分，本文采用 softmax 松弛技术，将属性选择操作转化为连续的优化问题：

$$\alpha_i = \text{softmax}(\beta \cdot \mathcal{L}(\mathcal{A}_i, \mathcal{S})) \quad (3-16)$$

其中， α_i 表示第 i 个属性的权重， β 是温度参数，用于控制 softmax 函数的平滑程度。

利用 ATPrompt 生成的文本提示，本文通过文本编码器将其转换为文本特征。文本特征生成过程如下：

$$T^{(l)} = \text{TextEncoder}(P^{(l)}) \quad (3-17)$$

其中， $P^{(l)}$ 是第 l 层的文本提示， $T^{(l)}$ 是生成的文本特征。为了使文本特征与视觉特征在相同的语义空间对齐，本文使用多层感知机（MLP）对文本特征进行映射：

$$T_{\text{mapped}}^{(l)} = \text{MLP}^{(l)}(T^{(l)}) \quad (3-18)$$

其中， $\text{MLP}^{(l)}$ 是第 l 层的多层感知机。

在得到映射后的文本特征后，本文将视觉特征和文本特征进行逐元素加权融合：

$$F_{\text{fused}}^{(l)} = \alpha^{(l)} F_{\text{mapped}}^{(l)} + (1 - \alpha^{(l)}) T_{\text{mapped}}^{(l)} \quad (3-19)$$

其中， $\alpha^{(l)}$ 是第 l 层的融合权重，用于平衡视觉特征和文本特征的贡献。这些权重通过训练过程学习得到。

3.2 实验验证

3.2.1 实验配置

为了全面验证本系统在医学图像异常检测任务中的有效性与泛化能力，本文精心设计并实施了一套完整的实验配置方案，涵盖了硬件环境、数据准备、超参数设置以及训练过程监控等多个关键方面。实验在本地部署的高性能计算平台上完成，采用 Python3.10 和 PyTorch2.0 框架进行实现。主干模型选用了视觉-语言预训练模型 CLIP（ViT-L/14），并在其基础上引入多级视觉特征适配模块（MVFA）进行轻量级微调，以更好地适应医学图像异常检测任务。所有输入图像均统一调整为 256×256 尺寸，并进行归一化处理，以确保图像数据的一致性和可比性。针对模型训练，采用 AdamW 优化器，并设置了自定义的超参数组合（初始学习率为 $5e-4$ ，批量大小为 12），训练总轮次为 60。在训练过程中引入验证集监控策略，通过动态评估 AUC 与损失曲线，确保模型在有限样本条件下的收敛性与鲁棒性。具体的实验配置项及参数说明如下表所示：

表 3-1 实验配置与超参数设置表

配置项	参数说明
操作系统与环境	Ubuntu 22.04, Python 3.10, PyTorch 2.0, CUDA 11.8
硬件平台	NVIDIA RTX A6000 48GB 显卡
视觉主干模型	CLIP ViT-L/14, 冻结主干, 插入 MVFA 多级适配器
图像输入尺寸	256×256 , 三通道图像归一化
数据集	BMAD 基准集 (含 BrainMRI、LiverCT、RESC、ChestXray、OCT17 等)
训练任务	图像级异常分类 (AC) 与像素级异常分割 (AS)
优化器与策略	AdamW, 初始学习率 $5e-4$, 权重衰减 $1e-2$
批量大小	12
训练轮数	60epochs
评估机制	验证集监控 AUC、loss; 保存最优模型; 无预训练特征库复用
随机性控制	设置固定随机种子以保证实验可重复性

3.2.2 性能指标

为了全面评估本系统在医学图像异常检测任务中的有效性与鲁棒性，本文采用 AUC（Area Under the ROC Curve）作为核心评价指标。AUC 是一种广泛使用的无阈值

指标，能够有效反映模型对正负样本的判别能力，且不受类别不平衡的影响。该指标在图像级异常分类（AC）和像素级异常分割（AS）任务中均具有重要的应用价值。

在实验中，我们分别计算了每个数据集上的图像级分类 AUC 和像素级分割 AUC，并对其进行了详细的分析和比较。后续的模型优化和改进需要有力的依据，而这些指标能够全面衡量模型在不同任务和数据集上的性能表现，从而为优化和改进提供支持。

3.2.3 实验结果

为了验证所提出的 MedVFA 模型在多模态医学图像下的通用性与优越性，本文在六个公开医学图像数据集上进行了实验，包括：BrainMRI、LiverCT、RESC、ChestXray、HIS 和 OCT17。实验采用小样本设定（K=4），并与两类主流模型进行对比：检测类模型 YOLOv8 和视觉编码类模型 ViT（Vanilla）。实验结果包括定量评估指标与可视化热力图展示。

表 3-2 不同模型在数据集上的 AUC 性能对比（K=4）

模型	BrainMRI	LiverC T	RESC	ChestXray	OCT1 7	平均 AC	平均 AS
YOLOv8	76.52	81.03	83.45	74.61	91.76	79.94	85.10
ViT	83.07	86.45	88.20	77.88	95.84	84.63	88.32
MedVFA	92.44	97.30	96.18	81.95	99.38	91.99	94.66

3.2.4 结果分析

通过以上实验，我们可以得出以下几点结论：MedVFA 具备更优的异常判别能力：在图像级与像素级任务上均取得了显著领先，尤其是在医学图像模态多样、结构复杂的数据集（如 BrainMRI、LiverCT）上，性能优势更加明显。这表明 MedVFA 在处理复杂医学图像时具有更强的适应性和鲁棒性。对 ViT 主干的多层特征进行残差适配，MedVFA 实现了局部细节与全局语义的兼容，提升了模型对病灶区域的敏感性。这种多级特征融合机制使得 MedVFA 能够更好地捕捉医学图像中的异常信息，从而提高了模型的检测精度。

4 医学图像异常检测系统设计与实现

4.1 系统功能设计

为了更好地展示本次毕业设计中的数据，设计了一个图形界面，能够通过该界面对不同算法的医学图像异常检测效果进行直观的比较，以便判断出哪一种算法能够更好地完成医学图像异常检测任务。




图 4-1 系统功能结构

界面分为三部分：设置区域用于选择模型、输入医学图像、设定图像处理参数，结果区域显示结果统计信息；视图区域用于展示医学图像和检测到的异常区域。用户可以选择本地医学图像文件或使用摄像头拍摄图像，选择不同的模型进行异常检测，并查看检测结果。

4.2 系统实现与测试

4.2.1 用户管理模块

用户管理模块包括用户注册、用户登录和用户忘记密码找回等基础功能。用户注册时，系统通过表单收集用户的基本信息，并通过邮箱验证确保用户信息的真实性。登录功能则运用了基于令牌的身份验证机制，以此保障用户会话的安全性。密码修改功能允许用户在忘记密码或需要更改密码时，通过验证身份后进行密码重置操作。用户信息存储在后端数据库中，同时使用了哈希算法以确保密码的隐私安全。




图 4-2 用户注册与登录界面

4.2.2 检测模块

检测模块是系统的核心部分，实现了图像上传、模型选择、异常检测和结果展示等功能。用户可以上传医学图像，系统支持多种常见的医学图像格式，如 JPEG、PNG 等。用户可以选择不同的模型进行检测，包括 CLIP、ViT 和 YOLO 模型。检测模块调用相应的模型进行图像推理，生成检测结果。检测结果包括异常类别、可视化热力图、检测框等信息，以直观的方式展示给用户。




图 4-3 医学图像异常检测主界面




图 4-4 医学图像异常检测图片选择示例

4.2.3 结果展示模块

结果展示模块提供了检测结果的可视化，包括异常类别、热力图、检测框等。结果展示模块采用动态图表和图像标注技术，将检测结果以图形化的方式呈现给用户。用户可以查看详细的检测信息，如异常区域的坐标、异常类别的置信度等。此外，结果展示模块还提供结果对比功能，用户可以对不同模型的检测效果进行对比，直观地了解各模型的优缺点。




图 4-5 检测结果展示界面

4.2.4 评估模块

评估模块显示模型的评估指标，如准确率、F1 分数等，帮助用户了解模型性能。评估模块根据测试数据集的标注信息和模型的检测结果，计算准确率、召回率、F1 分数、AUC 等评估指标。这些指标以表格和图表的形式展示给用户，使用户能够全面了解模型在不同数据集上的性能表现，为模型的选择和优化提供参考依据。




图 4-6 模型性能指标对比

4.3 系统测试

4.3.1 测试目标

对系统的各功能进行测试，确保系统的稳定性和准确性。测试内容包括用户管理、图像检测、结果展示和模型评估等功能模块。

4.3.2 测试方法

在系统测试过程中，我们运用黑盒测试方法，依据需求规格说明书，精心设计了多组测试用例，以此全面检验系统各项功能的实际表现。这些测试用例不仅涵盖了系统的各个功能模块，更是从不同角度出發，模拟了用户在实际操作中可能遇到的多种输入场景，包括正常输入、边界值输入以及异常输入等。

具体来说，对于正常输入的测试用例，我们选取了符合系统输入要求的典型医学图像数据，以此验证系统在常规情况下的功能表现。边界值输入测试则着重关注系统在极端情况下的处理能力，通过输入边界值附近的医学图像数据，检验系统是否能够准确地进行异常检测并给出正确的结果。而在异常输入测试中，我们故意输入不符合系统输入要求的数据，例如格式错误或损坏的医学图像文件，以此来验证系统的稳定性和容错能力。

4.3.3 测试用例

以下是部分测试用例的示例：

表 4-1 测试用例表

测试 编号	测试 功能	输入数据	预期结果	实际结果	测试 结论
003	图像 上传	支持的医学 图像格式	图像上传成功，显示上 传成功提示	图像上传成功，显示上 传成功提示	通过
004	模型 选择	CLIP、ViT、 YOLO	模型选择成功，显示检 测结果	模型选择成功，显示检 测结果	通过
005	结果 展示	检测结果	以图形化方式展示，包 括热力图和检测框	以图形化方式展示，包 括热力图和检测框	通过
006	模型 评估	测试数据集	显示准确率、F1 分数等 评估指标	显示准确率、F1 分数 等评估指标	通过

4.3.4 测试结论

经过多轮测试，系统的各个功能模块均能正常工作，满足用户需求。测试过程中未发现重大缺陷，系统的稳定性和准确性得到了验证。系统界面友好，操作便捷，结果展示清晰明了，用户体验良好。在未来的开发工作中，我们将持续致力于优化系统性能，并不断扩充功能模块，以更好地满足广大用户日益多样化的需求。

5 总结与展望

5.1 本文工作总结

本研究提出了一种基于改进 CLIP 模型的跨模态医学图像异常检测框架，该框架通过多层级特征适配与可学习文本提示，有效提升了模型在零样本和少样本场景下的异常检测性能。我们引入多级残差适配器对 CLIP 进行优化，使其能够更好地适应医学图像领域，并设计了一种多层级语义映射策略，从不同语义层级提取和整合医学图像的特征。此外，我们还提出了基于 ATPrompt 的可学习文本提示方法，通过属性嵌入机制增强文本特征的表达能力，并利用可微分属性搜索方法自动选择最优属性组合。实验结果表明，该框架在多个医学图像数据集上均取得了显著的性能提升，验证了其在跨模态特征适配和异常检测任务中的有效性。

首先，模型通过多层级特征适配和语义映射，能够充分挖掘医学图像的多尺度信息，生成更具代表性和判别力的特征表示。其次，基于 ATPrompt 的可学习文本提示方法有效增强了文本特征的表达能力，并通过属性嵌入机制提高了跨模态特征对齐的准确性。此外，模型在零样本和少样本学习场景下表现出良好的泛化性能，能够处理多种医学成像模态和解剖区域的异常检测任务。在实际应用中，该模型可应用于医学图像辅助诊断系统，帮助医生快速、准确地识别医学图像中的异常模式，提高诊断效率和准确性。同时，模型的零样本和少样本学习能力使其能够在数据有限的情况下进行有效训练，降低了医学图像标注的成本和时间。

5.2 未来研究方向

未来可以进一步优化模型的适配模块，探索更高效的特征提取和融合策略。此外，还可以研究如何将更多的先验知识融入模型中，以进一步提升模型的性能。在扩展应用方面，可以将该模型应用于其他医学图像分析任务，如图像分割、器官定位等。还可以探索将该模型与其他先进的深度学习技术相结合，以进一步提高模型的性能和泛化能力。

在医学图像异常检测系统中集成更多的功能模块，如异常定位、异常分类、异常程度评估等，以提供更全面的异常检测结果。此外，还可以研究如何利用该模型进行在线学习，使其能够实时更新和优化模型参数，以适应不断变化的医学图像数据和诊断需求。

随着深度学习技术的不断发展，医学图像分析领域将呈现出多模态数据融合、个性化医疗、智能化诊断等趋势。多模态数据融合将整合多种医学成像技术和临床数据，为疾病诊断提供更全面的信息。个性化医疗将根据患者的个体特征和病史，为其提供定制化的诊断和治疗方案。智能化诊断将借助先进的深度学习模型和人工智能技术，实现医学图像的自动分析和诊断，提高诊断的准确性和效率。

致 谢

随着这篇毕业论文的完成，我站在大学生活的尾声，回望过去四年的求学之路，有努力的痛苦泪水也有收获的快乐。在此，我想向所有在我大学本科求学旅程中给予我支持和帮助的人表达我最诚挚的感激。

首先，我要向我的指导老师丁磊老师致以诚挚的感谢。在四年的本科学习生涯中，丁老师是我最为喜欢的教师之一。他的课堂很具有启发性和实践性，首次让我深刻体会到工科专业学生拥有这样一位可以言传身教的老师是多么的幸运。正是在丁老师的引导下，我初次接触并逐渐深入探索深度学习这一领域。他不仅以其渊博的知识和严谨的治学态度引领我领悟科研的真谛，更以清晰的指导为我指明了未来的发展方向。我还要感谢电子信息与人工智能学院的所有老师，他们的教诲和智慧如同灯塔，照亮了我前行的道路。每一位老师都在自己的领域内展现出了卓越的才华和深厚的学术造诣，他们的课程不仅丰富了我的知识体系，更激发了我对知识的渴望和对未知的探索。

感谢我的同学们，特别是那些与我一起参加竞赛的伙伴们。我们一起度过了无数个奋斗的夜晚，一起在实验室里探讨问题，一起在赛场上挥洒汗水。每一次的合作都是一次宝贵的学习经历，每一次的成功都是我们共同努力的结果。你们的才华、热情和团队精神不断激励着我，让我在学术的道路上不断前行。

我亦需向我的挚友们致以诚挚的谢意，他们构成了我大学生涯中最为珍贵的部分。每当我遭遇困境与挫折，正是他们为我提供支持与激励；而当我取得成就与进步时，他们亦与我共同分享那份快乐。我们的友谊超越了学术的界限，成为了我人生中最坚实的后盾。无论是在图书馆的安静角落，还是在校园的林荫小道，我们共同度过了许多难忘的时光。

最后，我要感谢我的家人和龙哥，你们是我永远的依靠和支持。无论我走到哪里，你们的爱总是伴随着我，给予我力量和勇气。那句“别怕有我们大胆去干的鼓励”时常萦绕在我的耳边，让我可以拥有勇往直前的自信，也可以毫无畏惧的追求我的梦想！！谢谢你龙哥，幸而有你，一次次指引着我朝着正确的方向出发，一次次鼓励和指点迷津，你和我的家人共同构成了我的力量源泉！

在这段学术旅程的每一个阶段，我都深感幸运，能有这样一群优秀的老师、同学和朋友陪伴在我身边。你们的每一份帮助、每一次鼓励、每一句建议，都成为了我前进道路上的宝贵财富。在未来的日子里，我将带着这份感激和收获，继续在学术的道路上探索和前行。再次感谢你们，愿我们的友谊和合作能够持续到永远。

参 考 文 献

- [1] Cai Y, Zhang W, Chen H, et al. MedIANomaly: A comparative study of anomaly detection in medical images[J]. arXiv,2024.
- [2] Haralick R M, Shanmugam K, Dinstein I. Textural features for image classification[J]. IEEE Trans Syst, Man, Cybern, 1973, SMC-3(6): 610-621.
- [3] Jardim S, António J, Mora C. Image thresholding approaches for medical image segmentation - short literature review[J]. Procedia Computer Science, 2023, 219: 1485-1492.
- [4] Ojala T, Pietikainen M, Maenpaa T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns[J]. IEEE Trans Pattern Anal Machine Intell, 2002, 24(7): 971-987.
- [5] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241.
- [6] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 2261-2269.
- [7] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [8] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 2999-3007.
- [9] Huang C, Jiang A, Feng J, et al. Adapting visual-language models for generalizable anomaly detection in medical images[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 11375-11384.
- [10] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.
- [11] Wang Z, Wu Z, Agarwal D, et al. Medclip: Contrastive learning from unpaired medical images and text[C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing. 2022: 3876.
- [12] Zhang X, Xu M, Qiu D, et al. Medclip: Adapting clip for few-shot medical image anomaly detection[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2024: 458-468.

- [13] Huang S C, Shen L, Lungren M P, et al. GLoRIA: A multimodal global-local representation learning framework for label-efficient medical image recognition[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: IEEE, 2021: 3922-3931.
- [14] Zhang Y, Jiang H, Miura Y, et al. ConVIRT: Contrastive learning for vision-language representation in medical imaging[J]. arXiv, 2022.
- [15] 郭振,刘静,仇大伟,等. 面向 2D 医学图像检测的 YOLO 算法研究综述 [J/OL]. 计算机科学与探索,1-22[2025-06-14].
<https://kns-cnki-net.webvpn.sust.edu.cn/kcms/detail/11.5602.TP.20250605.1513.004.html>.
- [16] Zhao Z, Liu Y, Wu H, et al. CLIP in medical imaging: A survey[J]. Medical Image Analysis, 2025, 102: 103551.
- [17] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [18] 薛振华,李强,黄超.视觉大模型驱动的像素级图像异常检测模型[J/OL].计算机用,1-11[2025-06-14].
<https://kns-cnki-net.webvpn.sust.edu.cn/kcms/detail/51.1307.TP.20250113.1451.012.html>.
- [19] 张凌晓,杜铁琛,唐存东.基于生成对抗网络的肺结节图像扩增与检测[J].南阳理工学院学报
- [20] 王楠,林绍辉,齐福霖,等.基于自监督学习的医学影像异常检测[J].计算机辅助设计与图形学学报,2025,37(03):474-483.
- [21] Schuhmann C, Beaumont R, Vencu R, et al. Laion-5b: An open large-scale dataset for training next generation image-text models[J]. Advances in neural information processing systems, 2022, 35: 25278-25294.
- [22] Manzari O N, Ahmadabadi H, Kashiani H, et al. MedViT: A robust vision transformer for generalized medical image classification[J]. Computers in Biology and Medicine, 2023, 157: 106791.
- [23] Lee G E, Kim S H, Cho J, et al. Text-guided cross-position attention for segmentation: Case of medical image[C]//Medical Image Computing and Computer Assisted Intervention – MICCAI 2023. Cham: Springer Nature Switzerland, 2023: 537-546.
- [24] Zhou K, Xiao Y, Yang J, et al. Encoding structure-texture relation with P-net for anomaly detection in retinal images[C]//Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 360-377.
- [25] Asiri A A, Shaf A, Ali T, et al. Advancing brain tumor classification through fine-tuned vision transformers: A comparative study of pre-trained models[J]. Sensors, 2023, 23(18): 7913.

- [26] Sobek J, Medina Inojosa J R, Medina Inojosa B J, et al. MedYOLO: A medical image object detection framework[J]. J Digit Imaging Inform med, 2024, 37(6): 3208-3216.
- [27] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. PMLR, 2020: 1597-1607.
- [28] Zhong Y, Xu M, Liang K, et al. Ariadne's thread: Using text prompts to improve segmentation of infected areas from chest x-ray images[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2023: 724-733.
- [29] Koleilat T, Asgariandehkordi H, Rivaz H, et al. Medclip-sam: Bridging text and image towards universal medical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2024: 643-653.
- [30] Irvin J, Rajpurkar P, Ko M, et al. Chexpert: A large chest radiograph dataset with uncertainty labels and expert comparison[C]//Proceedings of the AAAI conference on artificial intelligence. 2019, 33(01): 590-597.
- [31] Johnson A E W, Pollard T J, Berkowitz S J, et al. MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports[J]. Scientific data, 2019, 6(1): 317.
- [32] Mahapatra D, Bozorgtabar B, Ge Z. Medical image classification using generalized zero shot learning[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 3344-3353.
- [33] Ali H, Mohsen F, Shah Z. Improving diagnosis and prognosis of lung cancer using vision transformers: A scoping review[J]. BMC Med Imaging, 2023, 23(1): 129.
- [34] Li Z, Zhang Z, Zhao H, et al. Text compression-aided transformer encoding[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 44(7): 3840-3857.
- [35] Wang J, Kang G. Learn to rectify the bias of clip for unsupervised semantic segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 4102-4112.
- [36] Qin Z, Yi H, Lao Q, et al. Medical image understanding with pretrained vision language models: A comprehensive study[J]. arXiv preprint arXiv:2209.15517, 2022.
- [37] 毛天驰,李杨,李明,等.基于深度学习的急性缺血性脑卒中病灶分割与检测综述[J].计算机系统应用,2025,34(01):11-25.
- [38] 李树建.基于改进 YOLOv7 的医学 CT 图像病灶检测方法[J].电脑编程技巧与维护,2024,(10):150-152+166.

- [39] Li S, Cao J, Ye P, et al. ClipSAM: CLIP and SAM collaboration for zero-shot anomaly segmentation[J]. Neurocomputing, 2025, 618: 129122.
- [40] 胡显耀,靳聪明.基于扩散常微分方程的医学图像异常检测[J].浙江理工大学学报(自然科学),2024,51(06):851-860.
- [41] Zhang J, Huang J, Jin S, et al. Vision-language models for vision tasks: A survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024.
- [42] 山显英,张琳,李泽慧.深度学习驱动下的目标检测研究进展综述[J].计算机工程与应用,2025,61(01):24-41.
- [43] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [44] 陈迪,陈云虹,程红阳,等.面向生物医学数据库的图像边缘检测与分割技术研究[J].电子设计工程,2024,32(17):180-184.
- [45] Saueressig C, Berkley A, Munbodh R, et al. A joint graph and image convolution network for automatic brain tumor segmentation[C]//Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries. Cham: Springer International Publishing, 2022: 356-365.